

ВВЕДЕНИЕ · ЧТО ТАКОЕ GEN AI



LARGE LANGUAGE MODEL · ЯДРО GEN AI

Большая языковая модель — начитанный цифровой собеседник для деловых задач.

Программное ядро искусственного интеллекта, которое **«прочитало»** огромный объём текстов, документов и знаний и научилось видеть устойчивые связи между словами, понятиями, смыслами и контекстом.

Люди выражают смыслы через слова и структуры языка — поэтому система научилась распознавать, что в запросе главное, как элементы связаны и какой ответ уместен по смыслу.

Для бизнеса — **начитанный цифровой собеседник**, который понимает деловой язык, удерживает контекст и помогает работать с информацией через обычный человеческий запрос.

01 / 15 · ПОЧЕМУ ЭТО ВОЗМОЖНО СЕЙЧАС

Новый уровень зрелости языковых моделей.

Модели перешли от генерации текста к участию в рабочих контурах.

01 Генерация текста — отвечает — переформулирует — пишет черновики	02 Понимание контекста — читает документы — извлекает смыслы — работает с неструктурированным вводом	03 Работа с инструментами — вызывает функции — ищет в системах — получает данные из приложений	04 Исполнение шага процесса — собирает входные данные — готовит артефакт — передаёт результат дальше
--	--	--	--

вывод	Ключевой сдвиг: модель стала не только формулировать, но и участвовать в исполнении.
------------------	--

Выбор по качеству, экосистеме, стоимости и контуру развёртывания.

КРИТЕРИЙ	OPENAI	GOOGLE	ANTHROPIC	DEEPSEEK	GIGACHAT / YANDEXGPT	OPEN-WEIGHT / ОТКРЫТОЕ ПО
ПОЗИЦИОНИРОВАНИЕ	универсальная прикладная платформа	AI + cloud + корпоративные корпоративные сервисы	управляемость, код, agentic use	цена / качество и гибкость	российская экосистема и облака	суверенный on-premise контур
СИЛЬНЫЕ СТОРОНЫ	богатая экосистема и инструменты	мультимодальность и data-stack	надёжность и дисциплина поведения	агрессивная экономика	русский язык, локальная интеграция	контроль над данными и стеком
ГДЕ ОСОБЕННО УМЕСТЕН	быстрый старт и прикладные сценарии	организации в Google Cloud	код, контроль, управляемые агенты	гибкие сценарии и снижение бюджета	РФ-контур, B2B и госограничения	закрытый периметр, суверенные данные
ОГРАНИЧЕНИЯ	внешняя зависимость от поставщика	выигрыш сильнее в своей экосистеме	цена и доступность по рынкам	нужно отдельно строить контроль	ограниченнее мировая экосистема	требует сильной внутренней команды
ЗАКРЫТЫЙ КОНТУР	обычно внешний облачный контур	есть enterprise-контур и governance	важна дисциплина прав и протоколов	варианты зависят от окружения	доступны российские облачные контуры	максимальный контроль, больше ответственности
ЭКОНОМИКА И ЗРЕЛОСТЬ	зрелая платформа, быстрый запуск	сильна для крупных ландшафтов	дороже, но часто лучше управляется	сильнее в экономике, давит цены рынка	сильнее по языку, юрисдикции, поддержке	ТСО зависит от GPU, оценки и сопровождения

Вывод

Рынок уже сложился: вопрос не в наличии вариантов, а в **правильном критерии выбора**. Для предприятия важнее не известность модели, а практическая пригодность в решении бизнес-задач.

Ориентир по классу модели, а не буквальный рейтинг.

МЕТРИКА /	GPT-5.4	GEMINI 3.1 PRO	CLAUDE OPUS 4.7*	DEEPSEEK V3.2**	QWEN3-CODER-NEXT	GIGACHAT-3.1 ULTRA
GPQA / SUPERGPQA НАУЧНОЕ И ИНЖЕНЕРНОЕ РАССУЖДЕНИЕ	92.8	94.3	91.3*	81.0**	— н/д	48.9
SWE-BENCH / HUMANEVAL РЕАЛЬНЫЕ ИНЖЕНЕРНЫЕ ЗАДАЧИ РАЗРАБОТКИ	57.7 Pro	80.6	80.8*	66.0**	70.6	90.9 HumanEval
MMLU / MMMLU МНОГОЯЗЫЧНОЕ ЗНАНИЕ И ПЕРЕНОС МЕЖДУ ЯЗЫКАМИ	—	92.6	91.1*	—	—	84.2 / 82.7
КОНТЕКСТ МАКСИМАЛЬНЫЙ ОБЪЁМ ТЕКСТА В ОДНОМ ЗАПРОСЕ (ТОКЕНЫ)	272K (1M exp)	1M	1M*	128K	262K	131K
TOKEN EFFICIENCY НАСКОЛЬКО МОДЕЛЬ «ПРОЖОРЛИВА» ПО ТОКЕНАМ	★★★★★	★★★★☆☆	★★★★☆☆	★★★☆☆☆	★★★☆☆☆	★★★★☆☆

ЧТО ВИДНО СРАЗУ

—

верхний класс уже очень близок

—

Anthropic силён в agentic coding

—

DeerSeek остаётся ценовым ориентиром

ГДЕ НУЖНА ОСТОРОЖНОСТЬ

—

режимы тестирования различаются

—

часть цифр относится к соседней версии

—

длинный контекст не равен качеству

КАК ЧИТАТЬ ДЛЯ ENTERPRISE

—

сначала shortlist по классу модели

—

потом пилот на своих документах

—

отдельно считать latency и стоимость

Почему AI нельзя внедрять как обычный модуль автоматизации.

AI – **вероятностная технология**, поэтому требует другой инженерной дисциплины. Проблема кумулятивная: все риски проявляются одновременно.

01 · Достоверность Галлюцинации Правдоподобный, но неверный ответ без опоры на источник.	02 · Контекст Ограниченный контекст Модель не видит всю картину сразу и теряет значимые детали.	03 · Природа Недетерминированность Повторный запуск не всегда даёт идентичный результат.	04 · Контроль Сложность тестирования Нельзя проверить каждый ответ простым набором правил.
05 · Доверие Непрозрачность Без трассировки трудно понять, почему система решила именно так.	06 · Периметр Безопасность Нужно жёстко ограничивать доступ к данным и действиям.	07 · Экономика Стоимость владения Экономика ломается при длинном контексте и частых вызовах.	08 · Регулирование Правовые рамки Закрытый контур, права, аудит и журналирование обязательны.

Вывод Задача предприятия — не убрать неопределённость, а научиться ей управлять.

Надёжность достигается не одной моделью, а инженерными мерами.

ПРОБЛЕМА	ЧТО ИМЕННО ЛОМАЕТСЯ	КАК КОМПЕНСИРУЕТСЯ	ПРИМЕРЫ МЕТОДОВ
Галлюцинации / недетерминированность	Правдоподобный, но неверный или неповторяемый ответ.	Перевод ответа в проверяемое представление и внешняя проверка.	— DSL и форматы — схемы данных — детерминированные валидаторы — выполнение кода / автотесты
Невозможность формальной проверки	Не каждую задачу можно доказать алгоритмически.	Оценка на эталонном наборе похожих задач и сравнительная проверка.	— Golden Set — внутренний бенчмарк — разметка экспертами — LLM as a judge / A/B
Ограниченность контекста	Модель получает или слишком мало, или слишком много шума.	Многоступенчатый подбор релевантного контекста перед ответом.	— классический RAG — гибридный поиск — query rewriting / reranking — windowing и суммаризация
Стоимость и задержка	Контур становится дорогим или медленным при росте нагрузки.	Управление токенами, маршрутизация по сложности, расчёт экономики.	— сжатие контекста / кэширование — малые модели на простых шагах — batch и offline preprocessing — меньше вызовов модели

Вывод

Не ищем лучшую модель — мы обкладываем её слоями проверяемости, измеримости и инженерной экономии.

Не один запрос — а **управляемый контур**

01

Пользовательская задача

ЧТО НУЖНО ПОНЯТЬ

— чат или мастер

— формы и шаги

— подтверждение

— человек в контуре

02

Сбор контекста

ЧТО НУЖНО НАЙТИ · RETRIEVAL / RAG

— поиск фрагментов

— chunking

— векторный поиск

— reranking

03

Поиск оснований

НА ЧЁМ ОПЕРЕТЬСЯ · EVIDENCE

— индекс знаний

— цитирование

— трассируемость

— доказательная база

04

Рассуждение и шаг

ЧТО НУЖНО РЕШИТЬ · ORCHESTRATION

— системные инструкции

— роли и граф

— агенты

— контроль статуса

05

Вызов действия

ЧТО НУЖНО СДЕЛАТЬ · TOOLS / MCP

— functions

— маршрутизация

— внешние сервисы

— разрешённые действия

06

Формирование результата

ЧТО ОТДАТЬ ПОЛЬЗОВАТЕЛЮ · OUTPUT

— структурированный вывод

— JSON / поля

— валидация

— готовый артефакт

— СТЕК: LANGCHAIN, LANGGRAPH, LLAMAINDEX, DSPY, OPEN WEBUI + СЕРВЕРНАЯ ЛОГИКА

НА СТОРОНЕ КОРПОРАТИВНОЙ СИСТЕМЫ

Чтобы подключиться к AI-контуру, корпоративная система должна безопасно отдавать данные и принимать действия.

ERP

CRM

CMMS / EAM

MES

Service Desk

DMS

SQL / витрины

— API · ПРАВА ДОСТУПА · ПОНЯТНЫЕ СУЩНОСТИ · ЖУРНАЛ · СТАБИЛЬНЫЕ КОНТРАКТЫ

МЕЖДУ СИСТЕМОЙ И МОДЕЛЬЮ

Управляемый слой интеграции, который ограничивает действия и ведёт аудит.

— адаптер · сервисный слой

— MCP-сервер

— ограничение действий

— аудит и подтверждение

Вывод

Модель подключается не к корпоративному ландшафту вообще, а к **управляемому слою интеграции** поверх систем.

AI-агент создаётся и улучшается через цикл **измеримой эксплуатации**.

СБОРКА И ПРОВЕРКА

01 СЦЕНАРИЙ задача, пользователь, ценность, риск	02 ПРОЦЕСС входы, решения, действия, контроль	03 ИСТОЧНИКИ документы, системы, права доступа	04 ПРОТОТИП роль, инструкция, формат результата	05 КОНТРОЛЬ типовые и сложные кейсы, эталоны	06 МЕТРИКИ качество, стоимость, задержка, пороги
--	---	--	---	--	--

ЭКСПЛУАТАЦИЯ И УЛУЧШЕНИЕ

07 ДОРАБОТКА источники, ограничения, модель под задачу	08 ПИЛОТ реальные пользователи, замер эффекта	09 НАБЛЮДЕНИЕ журнал, панель метрик, сигналы деградации	10 УЛУЧШЕНИЕ разбор ошибок, версии, откат
--	---	---	---

ЭКСПЛУАТАЦИОННЫЙ КОНТУР	трасса выполнения	+	панель метрик	+	пороги тревоги	+	разбор деградации
-------------------------	-------------------	---	---------------	---	----------------	---	-------------------

ВЫВОД	Ключевая экспертиза — построить не только агента, но и систему, которая показывает, когда он стал хуже, дороже или рискованнее.
-------	--

Процессы с понятными входами и действиями.

Лучшие первые сценарии — там, где много текста, правил, повторяемых решений и ручной работы между системами

01 · Производство ТОиР разбор заявок · подготовка работ · поиск инструкций · черновики нарядов	02 · Данные НСИ нормализация описаний · поиск дублей · классификация · подсказки заполнения	03 · Сервис Первая линия поддержки ответы по базе знаний · маршрутизация · сбор данных · подготовка ответа	04 · Документы Регламенты и документация поиск требований · сравнение версий · извлечение условий · подготовка изменений
05 · Люди Обучение и подсказки помощник специалиста · объяснение процедур · тренажёр · сопровождение новичков	06 · Системы Внедрение систем разбор требований · подготовка инструкций · миграция описаний · поддержка	07 · Артефакты Отчётность и артефакты черновики отчётов · структурирование комментариев · сводки · подготовка писем	08 · Интеграция Работа между системами сбор данных · заполнение форм · проверка статусов · передача результата

КРИТЕРИЙ ПЕРВОГО СЦЕНАРИЯ	частота	×	трудоёмкость	×	управляемость риска	×	доступность данных
---------------------------	---------	---	--------------	---	---------------------	---	--------------------

ВЫВОД	Начинать логично с процессов, где можно измерить качество, стоимость и эффект.
-------	--

Пилот на одном из процессов с потенциалом снижения расходов.

Помогаем выбрать сценарии, построить инженерный контур и довести его до управляемой эксплуатации.

01 — Старт

Диагностика

— процессы

— данные

— риски

— ограничения контура

→ КАРТА СЦЕНАРИЕВ

02 — Фокус

Выбор пилота

— 2–3 сценария

— критерии успеха

— контрольные задачи

— экономика

→ ПЛАН ПИЛОТА

03 — Сборка

Построение агента

— архитектура

— поиск с источниками

— инструменты

— права и тесты

→ РАБОЧИЙ КОНТУР

04 — Контур

Эксплуатация

— мониторинг

— стоимость

— безопасность

— масштабирование

→ AI-СЕРВИС ПРЕДПРИЯТИЯ

ПРИНЦИП ВЛАДЕНИЯ

Контур остаётся у вас.

— развёртывание в вашем контуре

— безопасность управляется вашими правилами

— данные, журналы, права и настройки остаются у вас

— нет подписки и регулярных платежей нам за токены

ВЫВОД

Промышленный AI начинается там, где модель становится частью измеримой и управляемой инженерной системы.



— РАЗДЕЛ II

Наши кейсы.

Пять промышленных сборок прикладного AI: от нормализации НСИ до многоканальных агентов и контроля регрессий.

- 10 · SAPTO
- 11 · AST
- 12 · AI Tests
- 13 · Mingly
- 14 · Agentium

SAPTO — ИИ-сопоставление таможенных позиций с каталогом.

Автоматический подбор карточек каталога по строкам пакинг-листа с учётом ТН ВЭД, фото и эталонных поставок.

01 ПРОБЛЕМА

Пакинг-лист содержит сотни позиций с сырыми наименованиями. На каждую — 10–30 вариантов карточек с разными кодами ТН ВЭД и пошлинами.

Ручной подбор занимает основную часть рабочего времени оператора.

02 РЕШЕНИЕ

- Нормализация наименований с учётом фото товара — генерация поисковых тегов
- ИИ-ранжирование кандидатов с % уверенности и обоснованием выбора
- Приоритет эталонных карточек из прошлых поставок
- Пакетный запуск на всю заявку с прогрессом в реальном времени

03 РЕЗУЛЬТАТ

Сокращение времени обработки заявки ~ 80%

Оператор подтверждает одним кликом вместо ручного поиска

Встроенная валидация выявляет ошибки до отправки

ВЫВОД

ИИ берёт на себя рутинный подбор, оператор **контролирует только сомнительные позиции.**

AST — ИИ-сопоставление смет с каталогом товаров

Автоматический подбор товаров и работ по строкам сметы с нормализацией и валидацией.

01 ПРОБЛЕМА

Сметчик вручную ищет каждую из сотен позиций в каталоге поставщика — сравнивает наименования, артикулы, размеры.

На крупном проекте **это занимает до месяца** и неизбежно ведёт к ошибкам.

02 РЕШЕНИЕ

- ИИ нормализует наименования, формирует поисковые запросы и находит кандидатов в каталоге с уровнем уверенности
- Извлечение параметров из текста для расчёта стоимости работ
- Автоматическая валидация результатов
- Настраиваемые правила сопоставления без изменения кода

03 РЕЗУЛЬТАТ

Сокращение ручного труда с 1 месяца до 2 часов

Командой из 4 человек

Настраиваемые правила сопоставления без программистов

ВЫВОД

Модель сильна как исполнитель внутри рамки — **правила задаёт бизнес, а не ИИ.**

AI Tests — платформа тестирования LLM / STT пайплайнов

Golden Set + A/B конфигураций + LLM Judge — **контроль регрессий** вместо субъективных ощущений.

01 ПРОБЛЕМА

Смена модели, промпта или провайдера — и непонятно, стало лучше или хуже. Ручная выборка и Excel не дают воспроизводимой оценки.

Более качественная модель может быть в 10х дороже.

02 РЕШЕНИЕ

- Эталонный набор звонков (Golden Set) + именованные конфигурации
- Автоматические метрики качества (F1, WER, step accuracy) и стоимости
- LLM Judge для субъективной оценки
- A/B-сравнение конфигураций на одних данных

03 РЕЗУЛЬТАТ

Обоснованный выбор модели по данным:

- Качество
 - Стоимость
 - Скорость
- Контроль регрессий при каждом изменении пайплайна

ВЫВОД

Не ищем лучшую модель — **обкладываем её слоями проверяемости и измеримости.**

Minqly — ИИ-аналитика звонков и тренажёр продаж

Автоматическая расшифровка, анализ по скрипту и **тренажёр с ИИ-клиентом**.

01 ПРОБЛЕМА Руководитель не может проверить все звонки — выборочный контроль охватывает 5–10%. Новые менеджеры «учатся на боевых» и теряют сделки. Настройка скрипта и плейбука — трудоёмкий ручной процесс.	02 РЕШЕНИЕ – 100% звонков → автоматическая расшифровка и анализ по плейбуку – Этап воронки, выполнение скрипта, возражения, детерминанты – Тренажёр с ИИ-клиентом для безопасной отработки – Автозаполнение плейбука по реальным звонкам	03 РЕЗУЛЬТАТ Полная прозрачность отдела продаж Менеджеры тренируются без потери реальных сделок Настройка скрипта — за часы вместо дней
---	---	---

ВЫВОД Новый объект автоматизации — не только данные, но и рутинный труд менеджера.

Agentium — ИИ-сотрудники для бизнеса.

Один ИИ-агент — все каналы: [Telegram](#), [WhatsApp](#), [сайт](#), [телефония](#).

01 ПРОБЛЕМА

Бот для Telegram, WhatsApp и голосовой робот — три разных проекта. Простые боты не справляются со сложными сценариями.

LLM без RAG галлюцинирует о продукте. Настройка агента занимает дни.

02 РЕШЕНИЕ

- Один ИИ-сотрудник подключается ко всем каналам
- Визуальный конструктор сценариев — граф узлов, у каждого свой промпт
- RAG по документам компании
- Голосовой агент с потоковым STT / TTS
- Создание через МСР за минуты

03 РЕЗУЛЬТАТ

Единая логика диалога

на все каналы

Факты из реальных документов, не из воображения модели

Аналитика и контроль стоимости по каждой сессии

ВЫВОД

Ценность — переход от ответа на вопрос к **исполнению последовательности действий**.

ЗАКРЫТИЕ · ГОТОВЫ К ДИАГНОСТИКЕ

Спасибо.

Промышленный AI начинается там, где модель становится частью измеримой и управляемой инженерной системы.

Поговорим о вашем процессе.